

АНАЛИТИЧЕСКИЙ ОТЧЕТ

Курсовая работа по классическому машинному обучению

Прогнозирование IC50, CC50 и индекса селективности по молекулярным дескрипторам

Автор: Александр Кочкин

1. Цель и состав работы

Цель работы - оценить возможность прогнозирования трех химических показателей по набору молекулярных дескрипторов и сравнить несколько алгоритмов классического машинного обучения.

- Регрессия: IC50, CC50 и SI.
- Классификация: IC50 выше медианы, CC50 выше медианы, SI выше медианы и SI выше 8.
- Сравнение линейных моделей, KNN, случайного леса, градиентного бустинга и XGBoost.

2. Методика оценки

Ключевое исправление методики - групповое разбиение данных. Объекты с одинаковыми значениями дескрипторов объединялись в одну группу и не могли одновременно попадать в обучение и тест. Для подбора гиперпараметров использовалась групповая кросс-валидация. Это снижает риск завышения качества из-за утечки данных.

- Полный набор: 210 молекулярных дескрипторов.
- Сокращенный набор: 158 признаков после удаления константных и почти константных дескрипторов.
- Для регрессии целевая переменная преобразовывалась через $\log_{10}$; итоговые MAE и RMSE рассчитывались на исходной шкале.
- Для классификации основной метрикой подбора был F1; дополнительно оценивались Accuracy и ROC-AUC.
- Во всех задачах результаты сравнивались с простой базовой моделью.

3. Итоговые результаты

Задача	Лучшая модель	Основной результат	Baseline	Вывод
Регрессия IC50	Градиентный бустинг	MAE 139.48 mM	MAE 167.55 mM	Умеренное улучшение
Регрессия CC50	Случайный лес	MAE 315.93 mM	MAE 475.62 mM	Заметное улучшение
Регрессия SI	Случайный лес	MAE 132.05	MAE 136.00	Улучшение около 3%
IC50 выше медианы	KNN, 210 признаков	F1 0.709; ROC-AUC 0.753	F1 0.667	Умеренное качество
CC50 выше медианы	Случайный лес, 210 признаков	F1 0.774; ROC-AUC 0.830	F1 0.669	Лучший результат классификации
SI выше медианы	KNN, 158 признаков	F1 0.659; Accuracy 0.689	F1 0.664	По F1 baseline не превзойден
SI выше 8	XGBoost, 210 признаков	F1 0.394; ROC-AUC 0.612	F1 0.528	Задача решена слабо

Примечание по задаче SI > 8: в итоговую сводку включен подтвержденный результат на полном наборе признаков. Он показывает, что модель различает классы лучше случайности по ROC-AUC, но не превосходит наивный baseline по F1.

4. Основные выводы

- Наиболее предсказуемым показателем оказался CC50. И в регрессии, и в классификации модели заметно превосходят baseline; лучший классификатор - случайный лес с ROC-AUC 0.830.
- Для IC50 модели дают полезное, но умеренное улучшение. Лучшие результаты получены ансамблевыми методами и KNN.
- SI прогнозируется значительно хуже. В регрессии выигрыш относительно медианного baseline минимален, а при классификации выше медианы лучший F1 не превосходит baseline.
- Задача SI > 8 является самой сложной. Из-за дисбаланса классов простой прогноз положительного класса имеет высокий F1, а обученные модели не дают убедительного улучшения по этой метрике.
- Удаление константных и почти константных признаков не дает универсального улучшения. Эффект зависит от алгоритма: некоторым моделям сокращение помогает, другим ухудшает качество.
- Разница между лучшими моделями во многих задачах невелика. Поэтому выбор модели следует делать не только по одной тестовой выборке, но и по устойчивости результатов на повторных групповых разбиениях.

5. Рекомендации по продолжению исследования

- Повторить оценку на нескольких групповых разбиениях и представить среднее значение метрик с разбросом.
- Для SI отдельно исследовать экстремальные значения, поскольку они сильно увеличивают RMSE и ухудшают стабильность моделей.
- Добавить более информативные представления молекул: структурные отпечатки, графовые признаки или дополнительные химические дескрипторы.
- Для несбалансированной задачи SI > 8 дополнительно анализировать precision-recall curve, PR-AUC и подбор порога классификации, а не ориентироваться только на F1 при пороге 0.5.

6. Итог

Работа подтверждает, что молекулярные дескрипторы позволяют строить полезные модели для IC50 и особенно CC50. Для SI текущего набора признаков недостаточно для надежного прогноза: результаты близки к простым baseline-моделям. **Наиболее обоснованным практическим результатом является модель классификации CC50 выше медианы на основе случайного леса.**